


ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



BÁO CÁO NGHIÊN CỨU

**Nghiên cứu và xây dựng bộ lọc hậu xử lý biến thể
di truyền dựa trên các mô hình học máy nâng cao**

Sinh viên thực hiện: Trần Mạnh Hùng
Mã sinh viên: 20220068
Ngành/Lớp: Công nghệ thông tin Việt Nhật – IT-E6
Giảng viên hướng dẫn: PGS.TS. Lê Đức Hậu

Hà Nội, 2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

Sinh viên: Trần Mạnh Hùng

MSSV: 20220068

Tên đề tài: Nghiên cứu và xây dựng bộ lọc hậu xử lý biến thể di truyền dựa trên các mô hình học máy nâng cao

Nhận xét:

Hà Nội, ngày tháng năm 2026

Giảng viên hướng dẫn

PGS.TS. Lê Đức Hậu

LỜI CAM ĐOAN

Em xin cam đoan báo cáo này là kết quả nghiên cứu và thực nghiệm do em thực hiện dưới sự hướng dẫn của PGS.TS. Lê Đức Hậu. Các số liệu, bảng kết quả và nhận xét trong báo cáo được tổng hợp từ quá trình chạy thực nghiệm trên dữ liệu HG002 Illumina NovaSeq 250x và đánh giá bằng công cụ hap.py. Các tài liệu tham khảo, công cụ và phương pháp được sử dụng trong báo cáo đều được trích dẫn rõ ràng.

Em xin chịu trách nhiệm về tính trung thực của nội dung báo cáo.

Hà Nội, năm 2026

Sinh viên thực hiện

Trần Mạnh Hùng

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành tới PGS.TS. Lê Đức Hậu, người đã hướng dẫn, góp ý và định hướng cho em trong quá trình thực hiện đề tài. Những góp ý của thầy giúp em hiểu rõ hơn cách thiết kế thực nghiệm, cách so sánh các phương pháp lọc biến thể và cách trình bày kết quả nghiên cứu một cách khoa học.

Em cũng xin cảm ơn các thầy cô trong Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội đã trang bị cho em kiến thức nền tảng về lập trình, xử lý dữ liệu và học máy. Đây là cơ sở quan trọng để em có thể tiếp cận bài toán phân tích biến thể di truyền và ứng dụng các mô hình học máy nâng cao vào bài toán thực tế.

Do thời gian và kinh nghiệm còn hạn chế, báo cáo khó tránh khỏi thiếu sót. Em rất mong nhận được ý kiến đóng góp của thầy cô để tiếp tục hoàn thiện nghiên cứu trong giai đoạn tiếp theo.

Sinh viên thực hiện

Trần Mạnh Hùng

TÓM TẮT

Biến thể di truyền thu được từ quy trình gọi biến thể thế hệ mới thường bao gồm cả biến thể thật và biến thể nhiễu. Vì vậy, bước lọc hậu xử lý đóng vai trò quan trọng nhằm giảm số lượng biến thể dương tính giả, đồng thời giữ lại tối đa các biến thể thật. Báo cáo này trình bày quá trình nghiên cứu và xây dựng bộ lọc hậu xử lý biến thể di truyền dựa trên các mô hình học máy nâng cao, sử dụng dữ liệu HG002 Illumina NovaSeq 250x và bộ chuẩn Genome in a Bottle (GIAB).

Các phương pháp được so sánh gồm Hard Filter, Variant Quality Score Recalibration (VQSR), Variant Ensemble Filter (VEF), TabPFN và mô hình stacking kết hợp VEF với TabPFN. Thí nghiệm được thực hiện riêng cho SNP và INDEL. Các biến thể được đánh giá bằng hap.py theo các chỉ số Recall, Precision, F1-score, số lượng False Positive (FP) và False Negative (FN). Kết quả cho thấy với SNP, TabPFN đạt F1-score cao nhất, trong khi Stack đạt Precision cao nhất và số FP thấp nhất. Với INDEL, VQSR đạt F1-score và Precision cao nhất, còn VEF giữ Recall tốt nhất và FN thấp nhất. Kết quả bước đầu cho thấy các mô hình học máy có tiềm năng trong bài toán lọc hậu xử lý biến thể, đặc biệt khi được kết hợp với các phương pháp chuẩn hiện có.

Từ khóa: variant filtering, HG002, GIAB, Hard Filter, VQSR, VEF, TabPFN, stacking, hap.py.

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Tóm tắt	iii
Danh mục từ viết tắt	viii
1 GIỚI THIỆU	1
1.1 Bối cảnh	1
1.2 Mục tiêu nghiên cứu	1
1.3 Phạm vi nghiên cứu	2
1.4 Cấu trúc báo cáo	2
2 CƠ SỞ LÝ THUYẾT	3
2.1 Biến thể di truyền SNP và INDEL	3
2.2 Đánh giá biến thể với GIAB và hap.py	3
2.3 Hard Filter	3
2.4 Variant Quality Score Recalibration	4
2.5 Variant Ensemble Filter	4
2.6 TabPFN	4
2.7 Stacking ensemble	4
3 DỮ LIỆU VÀ PHƯƠNG PHÁP THỰC NGHIỆM	5
3.1 Bộ dữ liệu	5
3.2 Gán nhãn dữ liệu	5
3.3 Đặc trưng đầu vào	5
3.4 Thiết lập huấn luyện công bằng	5
3.5 Quy trình thực nghiệm	6
4 KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN	7
4.1 Kết quả trên SNP	7
4.2 Kết quả trên INDEL	7
4.3 Biểu đồ so sánh	8

4.4	Nhận xét tổng hợp	9
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	10
5.1	Kết luận	10
5.2	Hạn chế	10
5.3	Hướng phát triển	10
A	MỘT SỐ ĐOẠN LỆNH CHÍNH	12
A.1	Ví dụ lệnh hap.py	12
A.2	Ví dụ stacking	12

Danh sách bảng

4.1	Kết quả SNP nhóm theo metric	7
4.2	Kết quả INDEL nhóm theo metric	8

Danh sách hình vẽ

4.1	So sánh F1-score giữa các phương pháp	8
4.2	So sánh Precision giữa các phương pháp	8
4.3	So sánh số False Positive giữa các phương pháp	9
4.4	So sánh số False Negative giữa các phương pháp	9

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Ý nghĩa
NGS	Next-Generation Sequencing – giải trình tự thế hệ mới
VCF	Variant Call Format – định dạng lưu trữ biến thể di truyền
SNP	Single Nucleotide Polymorphism – biến thể đơn nucleotide
INDEL	Insertion/Deletion – biến thể chèn hoặc mất đoạn
GIAB	Genome in a Bottle – bộ chuẩn đánh giá biến thể
TP	True Positive – biến thể đúng được phát hiện
FP	False Positive – biến thể sai nhưng vẫn được gọi/giữ lại
FN	False Negative – biến thể thật bị bỏ sót
VQSR	Variant Quality Score Recalibration
VEF	Variant Ensemble Filter
TabPFN	Tabular Prior-data Fitted Network

CHƯƠNG 1. GIỚI THIỆU

1.1 Bối cảnh

Giải trình tự thế hệ mới cho phép phát hiện các biến thể di truyền trên quy mô toàn hệ gen. Tuy nhiên, kết quả gọi biến thể thường chứa cả biến thể thật và các biến thể nhiễu do lỗi giải trình tự, lỗi căn chỉnh, độ phủ không đồng đều hoặc đặc điểm phức tạp của vùng gen. Do đó, sau bước gọi biến thể, cần có bước lọc hậu xử lý nhằm loại bỏ các biến thể có khả năng là nhiễu.

Trong các quy trình phổ biến, Hard Filter và VQSR thường được sử dụng để lọc biến thể. Hard Filter dựa trên các ngưỡng cố định của các annotation như QUAL, QD, MQ, FS, SOR. VQSR sử dụng mô hình thống kê/học máy để học phân bố của biến thể tốt và biến thể nhiễu, từ đó gán điểm chất lượng cho biến thể [1]. Tuy nhiên, các phương pháp này có thể phụ thuộc mạnh vào ngưỡng, tập huấn luyện, kích thước dữ liệu và đặc điểm bộ dữ liệu.

Gần đây, các phương pháp học máy như VEF và TabPFN mở ra hướng tiếp cận mới cho bài toán lọc biến thể. VEF xem bài toán lọc biến thể như một bài toán học có giám sát, sử dụng dữ liệu đã có nhãn TP/FP từ bộ chuẩn để huấn luyện mô hình ensemble [3]. TabPFN là mô hình nền cho dữ liệu bảng, được tiền huấn luyện trên nhiều bộ dữ liệu tổng hợp và có khả năng dự đoán nhanh trên các bài toán tabular [6, 7].

1.2 Mục tiêu nghiên cứu

Mục tiêu của đề tài là nghiên cứu và xây dựng bộ lọc hậu xử lý biến thể di truyền dựa trên các mô hình học máy nâng cao. Các mục tiêu cụ thể gồm:

- Khảo sát các phương pháp lọc biến thể truyền thống và học máy: Hard Filter, VQSR, VEF, TabPFN.
- Xây dựng quy trình gán nhãn biến thể TP/FP bằng hap.py dựa trên bộ chuẩn GIAB HG002.
- Huấn luyện và đánh giá VEF, TabPFN và mô hình stacking trên SNP và INDEL.
- So sánh các phương pháp theo từng metric để đánh giá trade-off giữa Precision, Recall, FP và FN.

- Đề xuất hướng cải tiến mô hình stacking bằng meta-learner mạnh hơn như XGBoost.

1.3 Phạm vi nghiên cứu

Báo cáo tập trung trên một mẫu chuẩn HG002 với dữ liệu Illumina NovaSeq 250x. Các biến thể được tách riêng thành SNP và INDEL. Kết quả đánh giá được lấy từ các dòng PASS của file `happy.summary.csv`. Đây là bước thử nghiệm ban đầu; các hướng mở rộng sẽ bao gồm đánh giá trên nhiều mẫu, nhiều độ phủ và nhiều pipeline gọi biến thể khác nhau.

1.4 Cấu trúc báo cáo

Báo cáo gồm năm chương chính. Chương 1 trình bày bối cảnh, mục tiêu và phạm vi nghiên cứu. Chương 2 giới thiệu cơ sở lý thuyết về biến thể di truyền, đánh giá biến thể và các phương pháp lọc. Chương 3 mô tả dữ liệu, đặc trưng và quy trình thực nghiệm. Chương 4 trình bày kết quả và phân tích. Chương 5 đưa ra kết luận và hướng phát triển.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1 Biến thể di truyền SNP và INDEL

SNP là biến thể thay đổi một nucleotide tại một vị trí trên hệ gen. INDEL là biến thể chèn hoặc mất một đoạn nucleotide ngắn. Trong thực tế, INDEL thường khó gọi chính xác hơn SNP do ảnh hưởng của căn chỉnh, vùng lặp và độ phức tạp cục bộ của trình tự.

2.2 Đánh giá biến thể với GIAB và hap.py

Genome in a Bottle cung cấp các bộ chuẩn chất lượng cao cho các mẫu tham chiếu như HG002, hỗ trợ đánh giá độ chính xác của các pipeline gọi biến thể [5]. Công cụ hap.py thường được sử dụng để so sánh file VCF dự đoán với bộ truth set, từ đó tính các chỉ số TP, FP, FN, Recall, Precision và F1-score.

Các chỉ số chính được sử dụng trong báo cáo gồm:

$$Recall = \frac{TP}{TP + FN} \quad (2.1)$$

$$Precision = \frac{TP}{TP + FP} \quad (2.2)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (2.3)$$

Trong đó, TP là số biến thể đúng được phát hiện, FP là số biến thể sai vẫn được giữ lại, và FN là số biến thể thật bị bỏ sót.

2.3 Hard Filter

Hard Filter là phương pháp lọc dựa trên ngưỡng cố định của các annotation. Ví dụ, các biến thể có QD thấp, FS cao hoặc MQ thấp có thể bị loại bỏ. Ưu điểm của phương pháp này là đơn giản và dễ triển khai. Tuy nhiên, việc lựa chọn ngưỡng thường phụ thuộc vào kinh nghiệm và đặc điểm bộ dữ liệu, do đó có thể không tối ưu cho mọi trường hợp.

2.4 Variant Quality Score Recalibration

Variant Quality Score Recalibration (VQSR) là phương pháp lọc biến thể của GATK. Theo tài liệu GATK, VQSR sử dụng mô hình học máy/thống kê để học profile kỹ thuật của các biến thể tốt từ tập huấn luyện, sau đó sử dụng mô hình này để phân biệt biến thể thật và artifact [1]. VQSR thường hoạt động tốt khi có đủ dữ liệu và tập tài nguyên huấn luyện phù hợp.

2.5 Variant Ensemble Filter

VEF là một công cụ lọc biến thể dựa trên ensemble learning. Theo Zhang và Ochoa, VEF xem lọc biến thể như bài toán học có giám sát, trong đó mô hình được huấn luyện từ VCF đã có nhãn true/false dựa trên gold standard [3]. Sau khi huấn luyện, mô hình có thể được áp dụng lên các VCF mới có cùng đặc điểm pipeline.

2.6 TabPFN

TabPFN là mô hình nền cho dữ liệu bảng. Khác với các mô hình truyền thống cần huấn luyện từ đầu trên mỗi dataset, TabPFN được tiền huấn luyện trên nhiều bộ dữ liệu tổng hợp để học cách suy luận trên dữ liệu bảng. Khi nhận một dataset mới, mô hình sử dụng dữ liệu huấn luyện như ngữ cảnh và sinh dự đoán thông qua forward pass. Trong môi trường thí nghiệm, package tabpfn phiên bản 8.0.3 tải checkpoint tabpfn-v3-classifier-v3_default.ckpt, tương ứng với TabPFN v3.

2.7 Stacking ensemble

Stacking là phương pháp ensemble gồm hai tầng. Tầng đầu gồm các base learners, trong báo cáo này là VEF và TabPFN. Mỗi mô hình tạo ra xác suất dự đoán biến thể là TP. Tầng thứ hai là meta-learner, trong thí nghiệm hiện tại sử dụng Logistic Regression để học từ các score của VEF và TabPFN, từ đó sinh ra score cuối cùng.

$$X_{meta} = [p_{VEF}, p_{TabPFN}, |p_{VEF} - p_{TabPFN}|, \min(p_{VEF}, p_{TabPFN}), \max(p_{VEF}, p_{TabPFN})] \quad (2.4)$$

Trong các hướng thử nghiệm tiếp theo, meta-learner có thể được thay bằng XGBoost để học quan hệ phi tuyến phức tạp hơn giữa các score và feature gốc.

CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP THỰC NGHIỆM

3.1 Bộ dữ liệu

Bộ dữ liệu sử dụng trong báo cáo là mẫu HG002 thuộc bộ chuẩn GIAB, với dữ liệu giải trình tự Illumina NovaSeq 250x. File VCF đầu vào được tách riêng thành SNP và INDEL. Các biến thể được benchmark bằng hap.py với truth set và confident region tương ứng.

3.2 Gán nhãn dữ liệu

Đối với các mô hình học máy, nhãn được tạo từ file VCF đã annotate bởi hap.py. Các biến thể có nhãn TP được gán nhãn 1, còn biến thể FP được gán nhãn 0. Các biến thể không thuộc hai nhóm này không được sử dụng trong bước huấn luyện.

3.3 Đặc trưng đầu vào

Các feature chính được trích xuất từ VCF gồm:

QUAL, DP, MQ, FS, SOR, QD, ReadPosRankSum, BaseQRankSum

Sau bước xử lý missing value theo hướng gần với VEF gốc, các feature còn lại trong thí nghiệm chính gồm:

QUAL, DP, MQ, FS, SOR, QD

Các feature có tỷ lệ missing value cao hoặc phương sai quá thấp được loại bỏ. Trong tập train, các dòng còn chứa missing value được loại bỏ. Trong tập test/apply, missing value được thay bằng trung bình của từng feature.

3.4 Thiết lập huấn luyện công bằng

Để so sánh công bằng giữa VEF và TabPFN, cả hai mô hình được huấn luyện trên cùng một tập dữ liệu con có tối đa 10,000 biến thể. Tập này được lấy bằng stratified sampling nhằm giữ tỷ lệ TP/FP. Cấu hình này giúp đảm bảo sự khác biệt kết quả chủ yếu đến từ mô hình thay vì số lượng dữ liệu huấn luyện.

- VEF: ensemble gồm Random Forest, XGBoost và SVM.
- TabPFN: sử dụng `TabPFNClassifier` với checkpoint v3.
- Stack: sử dụng score của VEF và TabPFN làm đầu vào cho meta-learner Logistic Regression.

3.5 Quy trình thực nghiệm

Quy trình tổng quát gồm các bước:

1. Chạy `hap.py` để tạo nhãn TP/FP cho VCF.
2. Trích xuất feature từ VCF gốc.
3. Chia train/validation/test và tạo shared training set 10,000 mẫu.
4. Huấn luyện VEF và TabPFN trên cùng shared training set.
5. Dự đoán xác suất trên validation set để chọn threshold tối ưu theo F1-score.
6. Xuất lại VCF với nhãn PASS/FAIL dựa trên threshold.
7. Chạy lại `hap.py` trên VCF đã lọc để lấy kết quả benchmark chính thức.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

4.1 Kết quả trên SNP

Bảng 4.1 trình bày kết quả SNP theo từng metric để dễ so sánh trực tiếp giữa các phương pháp.

Bảng 4.1: Kết quả SNP nhóm theo metric

Metric	Hard Filter	VQSR	VEF	TabPFN	Stack	Tốt nhất
Recall (%)	99.2957	98.2679	99.2798	99.3223	99.3020	TabPFN
Precision (%)	99.2897	99.6702	99.7110	99.7232	99.7353	Stack
F1-score (%)	99.2957	98.9697	99.4949	99.5224	99.5182	TabPFN
FP	1116	511	453	434	415	Stack
FN	1102	2711	1134	1067	1099	TabPFN
TP	156349	154740	156317	156384	156352	TabPFN

Với SNP, TabPFN đạt F1-score cao nhất là 99.5224%, đồng thời có Recall cao nhất và FN thấp nhất. Stack có Precision cao nhất và số FP thấp nhất, cho thấy mô hình stacking có xu hướng lọc chặt hơn, giảm biến thể dương tính giả tốt hơn nhưng đánh đổi bằng việc tăng FN nhẹ so với TabPFN.

4.2 Kết quả trên INDEL


Bảng 4.2 trình bày kết quả INDEL theo từng metric.

Bảng 4.2: Kết quả INDEL nhóm theo metric


Metric	Hard Filter	VQSR	VEF	TabPFN	Stack	Tốt nhất
Recall (%)	95.8976	95.5247	95.8976	95.6542	95.7367	Hard Filter / VEF
Precision (%)	97.4896	98.5791	97.4896	97.7761	97.6943	VQSR
F1-score (%)	96.6871	97.0279	96.6871	96.7035	96.7056	VQSR
FP	647	351	647	570	592	VQSR
FN	1046	1140	1045	1107	1086	VEF
TP	24427	24333	24428	24366	24387	VEF

Với INDEL, VQSR đạt Precision và F1-score cao nhất, đồng thời có số FP thấp nhất. Ngược lại, VEF đạt số FN thấp nhất và TP cao nhất, cho thấy khả năng giữ lại biến thể thật tốt hơn. Stack nằm giữa TabPFN và VEF, đạt F1-score cao hơn nhẹ so với TabPFN nhưng chưa vượt VQSR.


4.3 Biểu đồ so sánh




Hình 4.1: So sánh F1-score giữa các phương pháp



Hình 4.2: So sánh Precision giữa các phương pháp



Hình 4.3: So sánh số False Positive giữa các phương pháp



Hình 4.4: So sánh số False Negative giữa các phương pháp

4.4 Nhận xét tổng hợp

Kết quả cho thấy không có một phương pháp duy nhất tối ưu trên tất cả các metric và loại biến thể. Với SNP, TabPFN có kết quả tổng thể tốt nhất theo F1-score, trong khi Stack tối ưu hơn về Precision và FP. Điều này phù hợp với mục tiêu lọc chặt, giảm biến thể sai. Với INDEL, VQSR vẫn là phương pháp mạnh nhất theo F1-score và Precision, trong khi VEF giữ Recall tốt hơn. Điều này phản ánh đặc điểm khó của INDEL: giảm FP thường dẫn đến tăng FN, và ngược lại.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Báo cáo đã trình bày quá trình nghiên cứu và xây dựng bộ lọc hậu xử lý biến thể di truyền dựa trên các mô hình học máy nâng cao. Trên bộ dữ liệu HG002 Illumina NovaSeq 250x, các phương pháp Hard Filter, VQSR, VEF, TabPFN và Stack được so sánh riêng cho SNP và INDEL bằng hap.py.

Kết quả cho thấy với SNP, TabPFN đạt F1-score cao nhất, trong khi Stack giảm FP tốt nhất. Với INDEL, VQSR đạt F1-score tốt nhất, còn VEF giữ FN thấp nhất. Điều này cho thấy hiệu quả của từng phương pháp phụ thuộc vào loại biến thể và mục tiêu tối ưu. Các mô hình học máy như VEF và TabPFN có tiềm năng lớn trong lọc hậu xử lý biến thể, đặc biệt khi được kết hợp trong các kiến trúc stacking hoặc hybrid model.

5.2 Hạn chế

Thí nghiệm hiện tại vẫn còn một số hạn chế:

- Mới đánh giá trên một mẫu HG002, chưa kiểm tra khả năng tổng quát hóa trên nhiều mẫu khác.
- TabPFN được giới hạn ở 10,000 mẫu train trong thiết lập fair comparison, trong khi dữ liệu biến thể thực tế có thể lên tới hàng triệu dòng.
- Bộ feature hiện tại chủ yếu gồm các annotation cơ bản từ VCF, chưa khai thác thêm thông tin ngữ cảnh vùng gen hoặc thông tin từ BAM.
- Meta-learner stacking hiện mới sử dụng Logistic Regression, chưa thử đầy đủ các mô hình phi tuyến như XGBoost.

5.3 Hướng phát triển

Các hướng phát triển tiếp theo gồm:

- Đánh giá trên nhiều mẫu GIAB khác như HG001, HG003, HG004.

- Thử nghiệm các độ phủ khác nhau để kiểm tra tính ổn định của mô hình.
- Thử meta-learner XGBoost trong stacking để học quan hệ phi tuyến giữa score của VEF, TabPFN và feature gốc.
- Thử chọn tập train cho TabPFN theo hard examples, bao gồm nhiều FP và TP khó thay vì lấy mẫu ngẫu nhiên stratified.
- Bổ sung thêm feature như genotype quality, allele balance, depth theo allele, context sequence hoặc mappability.

CHƯƠNG A. MỘT SỐ ĐOẠN LỆNH CHÍNH

A.1 Ví dụ lệnh hap.py

```
hap.py <truth.vcf> test.snp.TabPFN_fair.vcf \  
-f <confident_region.bed> \  
-r <reference.fa> \  
-o happy_snp_tabpfn_fair \  
--pass-only --type SNP
```

A.2 Ví dụ stacking

```
X_meta_val = make_meta_features(X_val, p_vef_val, p_tabpfn_val)  
X_meta_test = make_meta_features(X_test, p_vef_test, p_tabpfn_test)  
  
meta = LogisticRegression(random_state=42, max_iter=1000)  
meta.fit(X_meta_val, y_val)  
  
p_stack_val = meta.predict_proba(X_meta_val)[:, 1]  
p_stack_test = meta.predict_proba(X_meta_test)[:, 1]
```

TÀI LIỆU THAM KHẢO

- [1] GATK Team. *Variant Quality Score Recalibration (VQSR)*. Broad Institute GATK Documentation. URL: <https://gatk.broadinstitute.org/hc/en-us/articles/360035531612-Variant-Quality-Score-Recalibration-VQSR>
- [2] GATK Team. *How to filter variants either with VQSR or by hard-filtering*. Broad Institute GATK Documentation. URL: <https://gatk.broadinstitute.org/hc/en-us/articles/360035531112--How-to-Filter-variants-either-with-VQSR-or-by-hard-filtering>
- [3] Zhang, C. and Ochoa, I. (2020). *VEF: a variant filtering tool based on ensemble methods*. Bioinformatics, 36(8), 2328–2336. DOI: <https://doi.org/10.1093/bioinformatics/btz952>
- [4] ChuanyiZ. *VEF: Variant Ensemble Filter*. GitHub repository. URL: <https://github.com/ChuanyiZ/vef>
- [5] NIST. *Genome in a Bottle*. URL: <https://www.nist.gov/programs-projects/genome-bottle>
- [6] Hollmann, N. et al. (2025). *Accurate predictions on small data with a tabular foundation model*. Nature. URL: <https://www.nature.com/articles/s41586-024-08328-6>
- [7] Prior Labs. *TabPFN-3: Technical Report*. URL: <https://priorlabs.ai/technical-reports/tabpfn-3>
- [8] PriorLabs. *TabPFN – Foundation Model for Tabular Data*. GitHub repository. URL: <https://github.com/PriorLabs/tabpfn>